

补充材料 / SUPPLEMENTARY EVIDENCE

CampusOne

这些结论，您可以自己验证一遍

这份材料是做什么的

它不复述方案书。项目的核心主张是“模型的输出会被拦住，而且拦得住这件事可以被检验”，而录屏无法证明一次拒绝是真的校验还是写死的分支。所以这里只放两类东西：可以由评审亲自点开复现的操作，以及系统运行时留下的原始记录。

60 秒

可自行复现

三个动作，浏览器即可

105

自动化测试

全部通过

3

已修复缺陷

含模型原话与复验

参赛单位 厦门大学

团队名称 厦马智教

团队成员 胡博（队长）、温广琛、许佳锋

指导教师 张盈谦

版本 2026 年 9 月 · 初赛提交版

说明：本材料引用的每一条结果都来自对运行中系统的实测，均可按第 01 节的方式复现。

01 请您自己验证

两个入口，三个动作。不需要装任何东西，也不需要我们的密钥。

入口	地址	说明
浏览器版（推荐）	https://echo5177.github.io/campusone-agentflow/	无需密钥，打开即用，AI 为本地可复现输出
私有站点	https://campusone-agentflow.atticus-5951.chatgpt.site	接入真实模型 deepseek-chat，展示真实调用耗时

两个入口的规则引擎、校验层和状态机完全一致，区别只在 AI 那一层是真实调用还是本地可复现输出。下面三个动作在任一入口都成立，各自一分钟内可以看到结果。

动作一：让程序否掉一个明显不合规的申请

步骤	操作	应当看到
1	在“申请办理”页，把“预计人数”改成 800（该场地容量 120 人）	右侧事实卡片中“预计人数”由“容量可用”变为“需调整”
2	点击“规则预检”	六条规则逐条给出判定，VENUE-CAP-001 标红并写明“预计 800 人，超过场地容量 120 人”
3	点击“让 AI 帮我整理”	AI 文字上方先出现红色“规则预检未通过 · 1 项”，并注明“以上结论由规则引擎判定，不由模型给出”

这一步在证明什么

合规判定不经过模型。模型看得到规则结论，但改不了它，也不被允许自己下结论。第 05 节给出了这条约束缺失时模型实际说过的话。

动作二：让模型说一条不存在的规则，看它被拦下来

步骤	操作	应当看到
1	在右侧“演示模型异常”下拉框中选择“虚构规则”	下方提示说明该开关在真实模型下同样生效
2	点击“运行表单整理”	AI 面板显示“输出已拒绝”，错误码为 RULE_NOT_FOUND
3	打开左侧“AI 运行证据”	该次运行被记录为“已拒绝”，保留任务、模型、耗时与错误码

注入方式是把一个不存在的规则编号 VENUE-RULE-999 放进模型输出中已声明的字段里。校验器扫描整份输出，发现编号不在规则目录中即拒绝。被拒绝的输出不会显示给用户，业务状态也不发生任何变化。

动作三：以申请人身份直接批准自己的申请

这一条需要用开发者工具发一个请求，因为界面上根本没有这个按钮。在私有站点按 F12 打开控制台，粘贴：

```
fetch('/api/case', { method: 'POST',
  headers: { 'Content-Type': 'application/json' },
  body: JSON.stringify({ action: 'transition', to: 'approved',
    role: 'admin', actorId: 'admin-zhou' })
}).then(r => r.status)
```

返回 409，案件状态不变。业务接口不读取请求里的身份字段，操作角色只认服务端会话，所以伪造身份这条路在接口层就是堵死的。

02 判定与证据是怎么绑定的

每条规则有编号，每条编号有制度依据，模型只能引用真实存在的编号。

规则编号	判定内容	制度依据
VENUE-REQ-001	必填字段完整，并逐项列出缺项名称	KB-VENUE-001
VENUE-TIME-001	结束时间晚于开始时间	KB-VENUE-001
VENUE-CAP-001	人数为正整数且不超过场地核定容量	KB-VENUE-001、KB-SAFETY-001
VENUE-SLOT-001	与已占用时段无重叠	KB-VENUE-001
VENUE-EQP-001	设备需求可被该场地满足	KB-VENUE-002
VENUE-HOUR-001	在场地开放时间内且不跨日	KB-VENUE-003

规则目录、证据白名单和知识检索读的是同一份定义，所以一条规则不可能只存在于其中一处。模型输出里出现的每一个编号都会被比对：规则编号要在目录中，证据编号要指向真实存在的表单字段、场地事实、知识条目或管理员填写的退回意见。

输出要过的几道关

- 01 结构校验：发给模型的契约由校验用的同一份 Schema 直接生成，描述和校验不会不一致。
- 02 规则编号校验：扫描整份输出，出现目录里没有的编号即拒绝。
- 03 证据编号校验：引用的证据必须真实存在。

04 语义校验：已退回的案件，通知草稿中不得出现“等待审批”“无需修改”这类与状态矛盾的表述。

拒绝码	触发条件	是否重试
INVALID_JSON	返回的不是合法 JSON	是
SCHEMA_MISMATCH	字段缺失、多余或类型不符	是
SEMANTIC_CONFLICT	内容与案件当前状态矛盾	是
RULE_NOT_FOUND	引用了不存在的规则编号	否
EVIDENCE_NOT_FOUND	引用了不存在的证据编号	否
MODEL_TIMEOUT	模型未在预算内返回	否

可重试的三类会带着校验器的具体报错再问模型一次，仍不通过就降级为固定文案。每一次尝试单独留痕，被拦下的那次也留在运行记录里，不会被悄悄抹掉。

03

故障注入实测

三类任务乘三种故障，九种组合逐一实测。

演示开关不是把结果写死。它先让系统真实调用一次模型，再对返回结果注入故障；超时则是把请求预算收缩到真实中断为止。所以证据面板里的拒绝理由和耗时都是实测值。

任务	非法 JSON	虚构规则	模型超时
表单整理 form_assist	INVALID_JSON	RULE_NOT_FOUND	MODEL_TIMEOUT
审核摘要 review_brief	INVALID_JSON	RULE_NOT_FOUND	MODEL_TIMEOUT
退回通知 return_message_draft	INVALID_JSON	RULE_NOT_FOUND	MODEL_TIMEOUT

九种组合的错误码全部符合预期。超时故障实测约 614 毫秒后中断，记录的是真实等待时间而不是预先填好的数字。三次故障期间案件状态均未发生变化。

04

我们主动找出并修复的三个缺陷

把真实出错的原话放出来，比声称系统可靠更能说明这套约束在做事。

下面三条都是开发过程中真实出现过的。它们的共同点是：接口全部返回成功、自动化测试全绿，但模型说的话是错的。这正是我们把“模型语义”单独列为一类验收项的原因。

缺陷一：模型对着一条正在失败的规则说了假话

把预计人数改成 800（场地容量 120）后运行表单整理，规则 VENUE-CAP-001 正在失败，模型却回复：

修复前·模型原话

“已验证的活动信息完整，符合场地申请要求。”

原因是表单整理当时是唯一不跑规则引擎的任务，只把裸表单发给模型。它没有任何规则结论，被要求解释自己的工作时就自行补了一个合规判断。修复后同一输入的回复：

修复后·模型原话

“申请表单必填字段齐全，时间顺序有效，且当前时段无冲突、设备需求可满足、在场地开放时间内。但预计人数 800 人超过场地容量 120 人，因此申请未通过校验。建议调整活动人数或更换更大场地。”

复验：同一输入连续 6 次真实模型调用，每次都如实说明超出容量，无一次给出合规结论。

缺陷二：退回通知写成了“已提交、等待审批”

对一份已被管理员退回的申请生成退回通知，模型输出：

修复前·模型原话

“您的场地申请已提交，我们正在处理中。请留意后续通知。”

这条通知通过了当时的全部校验，因为它结构合法、没有引用假编号。问题在于内容与案件状态相反。该任务同样没有拿到案件状态：给它一份规则全过的申请，它合理地推断案件还在审批中。修复后：

修复后·模型原话

“您好，您提交的“2026 秋季社团招新宣讲会”场地申请已收到。经初步核对，预计参加人数为 80 人，已接近场地容量上限（120 人）。为保障活动安全有序进行，请您补充现场秩序维护与疏散安排的具体说明，并重新提交申请。”

处置分三层：接口从服务端读取当前状态与管理员填写的退回意见并传入；新增语义校验，已退回状态下出现等待审批类表述直接拒绝并允许重试；模型被拒时的降级文案直接引用管理员原话，保证通知里始终有申请人真正需要的那一句。复验：连续 8 次真实模型调用全部通过，无矛盾表述，每次都引用了管理员填写的原句。

缺陷三：故障演示只在本地模式生效

三种模型异常的演示开关原本接在本地模式分支上，接入真实模型后点击没有反应；其中“虚构规则”还会报成结构错误，与演示口径不符。原因是故障注入与模型模式耦合，且注入方式对不同任务不一致。修复后故障与模型模式解耦，先真实调用再注入，超时改为收缩真实请求预算。复验即第 03 节的九种组合，全部符合预期。

05

自动化测试与实测记录

测试证明接口与状态路径正确；模型语义另行实测。

105

自动化测试

12 个测试文件全部通过

9

闭环事件

含一次退回与修订 V2

0

高危依赖

Critical / High

测试覆盖方案书列出的 T01 至 T21 全部用例，其中包含浏览器演示版的相关用例。三份材料引用的数字取自同一次运行。

权限、并发与流程

- 完整状态链走通：草稿到提交、接件、退回、修订 V2、再提交、批准、归档，共 9 条事件，V1 与 V2 并存。
- 申请人在请求体里伪造管理员身份直接批准，服务端返回 409，案件状态未变。
- 四个并发的重复提交只产生一条事件，四个请求均返回 200，幂等键由服务端推导。
- 空退回意见的退回请求被拒绝，返回 RETURN_REASON_REQUIRED。
- 两个不同会话各自持有独立案件，互不影响；重置演示只清除调用者自己的案件。

真实模型（deepseek-chat）

实测项	结果
表单整理连续 6 次	全部通过校验，单次耗时 1.2 至 1.4 秒
超容量输入下的表述	6 次全部如实说明超出容量，无合规断言
退回通知连续 8 次	全部通过，无等待审批类矛盾表述，均引用管理员原句
三类任务 × 三种故障	9 种组合错误码全部符合预期
超时故障	约 614 毫秒后中断，记录为真实耗时

06

边界声明

把没做的事说清楚，比把做过的事说满更重要。

事项	当前状态
场地、制度与申请数据	全部为模拟数据，不含任何真实师生信息
身份切换入口	演示专用。生产环境删除该路由，改由学校统一身份认证写入同一会话
知识检索	按规则绑定取用四份制度文件，不是向量召回
已占用时段	静态演示数据，未接入真实排期系统
退回通知	只产出草稿，界面没有发送动作，不构成站内或邮件送达
效率提升数据	尚未开展真实试点，本阶段不给出任何百分比

关于口径

自动化测试通过只说明接口与状态路径正确，不代表模型文案的业务语义一定正确。本项目两次语义缺陷都是在接口全绿的情况下发现的，因此把模型语义单独列为一类验收项，并在第 04 节公开了原始出错记录。

下一阶段先邀请至少 3 名同学试用，记录完成时间与看不懂的字段，再建立审批时长、退回率和人工采纳率基线。这些数字现在还没有，所以不写。